简泽鑫

(+86) 155-7423-3383 jianzexin25z@ict.ac.cn xinchen-jzx.github.io



研究方向：

- 运行时
- 机器学习系统
- 大语言模型

我将继续寻找，就算这无尽的星辰令我的寻找希望渺茫，就算我将单枪匹马。

教育背景

2021.09 ~ 2025.06
计算机科学与技术
国防科技大学
工学学士, 计算机学院
导师: 曾坤 - 副研究员

2025.09 ~ present
计算机科学与技术
中国科学院大学
博士研究生, 计算技术研究所
导师: 崔慧敏 - 教授; 王晨曦 - 副教授

实习经历

华为诺亚方舟实验室 **研发实习生** *2025-12~2026-09*
CloudMatrix384, Ascend, MemFabric, MoE EP, HCCL

- 联合主导 **MemFabric**：面向昇腾超节点池化 DRAM/HBM 等异构内存，提供全局虚拟地址直接访问。目前论文在投。
- 联合主导 **CATCCOS**（Compute-Communication Overlap Subroutines）：设计计算-通信重叠子程序，隐藏集合通信时延。目前论文在投。
- 联合主导 **MegaKernel**：将多层计算与通信融合为持久化 kernel，降低 launch 开销。目前论文在投。
- 主导 **STAP**（Sub-Tile Asynchronous Parallelism）：实现子 Tile 级异步并行，提升计算与数据搬运重叠。目前论文在投。
- 主导 **Ascend-MoonEP**：将 MoonEP 专家并行通信适配至昇腾，支撑 MoE dispatch/combine。

北大信息技术高等研究院 **编译器研发实习生** *2025-05~2028-01*
C/C++, MLIR, RISCV, Compiler Design

- 使用 C/C++ 开发，基于 MLIR 构建面向不同 RISC-V SRAM 存算一体芯片的自动后端优化编译器
- 将应用程序翻译到统一中间表示，进行应用特征分析，识别可加速计算部分并转为特定 RISC-V 加速指令

Research & Publications

- **[Arxiv'26]** Jin Qin*, Tiancheng Hu*, Shiyan Wang, Junhao Hu, **Zexin Jian**, Yuzheng Wang, Haoyu Li, Chunwei Xia, Ying Liu, Pixian Zhan, Di Wang, Zhongzhe Hu, Huimin Cui, Tao Xie, Chenxi Wang. *CascadeEP: Asynchronous Expert Execution for MoE Prefill under Attention Imbalance*.
- **[ICS'26 workshop]** **Zexin Jian**, Shuhui Jia, Chunwei Xia, Di Wang, Chenxi Wang. *RV-IR: An MLIR-Based Architecture-Aware Intermediate Representation for Heterogeneous RISC-V AI Acceleration*.
- **[NeurIPS'24 CCF-A]** Zhihua Wen, Zhiliang Tian, **Zexin Jian**, Zhen Huang, Pei Ke, Yifu Gao, Minlie Huang, Dongsheng Li. *Perception of Knowledge Boundaries for LLMs via Semi-open-ended Question Answering*.
- **[ACL'23 CCF-A]** Zhihua Wen, Zhiliang Tian, Zhen Huang, Yuxin Yang, **Zexin Jian**, Changjian Wang, Dongsheng Li. *GRACE: Gradient-guided Controllable Retrieval for Augmenting Attribute-based Text Generation*.

项目经历

LLM as Compiler **中科院计算技术研究所** *2024-09~2025-04*
LLM, Compiler Design, Machine Learning System

- 负责在大处理器芯片模型（LPCM）框架中设计并优化编译模块，实现源代码到硬件适配机器代码的自动转换
- 通过引入大语言模型（LLM），成功实现了编译过程的自动化，支持硬件-软件协同设计。推动了编译器从人机协作到自动化的多级优化

mini RustOS **国防科技大学** *2024-09~2024-12*
Rust, X86, OS Design, Hybrid Kernel

- 使用 Rust 开发，从零实现了一个 X86 架构的实验性操作系统内核

- 本项目的出发点是探索不同的内核架构对内核安全性与性能的影响并尝试权衡二者。从宏内核出发，吸收借鉴微内核的设计模式来提高安全性的同时保证一定的性能

SysY Compiler **国防科技大学** *2024-02~2024-08*

C/C++, LLVM, RISCV, Compiler Design, Multi-Threads Parallel

- 使用 C/C++ 开发，为 SysY2022（C 语言子集）实现了一个功能齐全的编译器系统
- 主要工作包括前端的词法分析和语义分析，以及面向 RISC-V 架构的底层代码生成和优化

GROVE **国防科技大学** *2023-05~2023-10*

Python, LLM, Controllable Text Generation

- 主导研发 GROVE 检索增强故事生成框架，结合大语言模型、条件检索与迭代推理机制生成复杂情节故事
- 创新设计**追问式提示（Asking-Why）**构建证据链用于补全背景与逻辑，提升故事可读性与丰富度
- 在多个评测维度上取得领先效果，显著提升模型的复杂性、创造性与可控性

获奖情况

国家励志奖学金	**2023/2024**	*2023-09~2024-09*
国防科技大学计算机学院	**优秀学员·学习标兵**	*2021-09~2025-06*
全国大学生计算机系统能力大赛操作系统设计赛	**三等奖**	2025-08
第七届开源创新大赛“红山开源”操作系统-开源任务挑战赛	**一等奖**	2024-11
全国大学生计算机系统能力大赛编译系统设计赛	**二等奖**	2024-08
中国高校计算机大赛-团体程序设计天梯赛	**三等奖**	2024-04
第七届全军军事建模竞赛	**二等奖**	2023-12