简泽鑫

(+86) 155-7423-3383 jianzexin25z@ict.ac.cn xinchen-jzx.github.io



中国科学院计算技术研究所博士二年级学生在读， 研究方向:

- 运行时
- 机器学习系统
- 大语言模型

教育背景

2021.09 ~ 2025.06
计算机科学与技术
国防科技大学
工学学士, 计算机学院
导师: 曾坤 - 副研究员

2025.09 ~ present
计算机科学与技术
中国科学院大学
博士研究生, 计算技术研究所
导师: 崔慧敏 - 教授; 王晨曦 - 副教授

实习经历

华为诺亚方舟实验室 **研发实习生** *2025-12~2026-09*
Ascend, MemFabric, MoE, MegaKernel

- **MemFabric**: 面向昇腾超节点的 **DRAM/HBM 异构内存池**, 提供跨进程统一的全局虚拟地址空间, 支持 NPU 算子直接访问跨节点内存及高效数据传输。相关论文在投。
- **CATCCOS**（Compute-Communication Overlap Subroutines）: 面向昇腾 NPU 设计并实现**可复用的计算–通信重叠子程序**，通过计算与通信分块解耦、Block Cluster 级流水同步及 Rank 感知调度，实现 GEMM/GMM 与多类集合通信的高效重叠，降低分布式大模型计算中的通信等待开销。相关论文在投。
- **MegaKernel**: 面向昇腾 NPU 大模型解码优化，研发持久化 Megakernel 编译与运行时系统；通过 **Tile 级依赖分析与图压缩**实现跨算子流水，结合 **AICPU 带外调度、寄存器通知与异构任务派发**协调 Cube/Vector 执行，并以 **Early Handoff** 分离调度就绪与数据就绪，将后继任务准备与前驱计算重叠。相关论文在投。
- **STAP**（Sub-Tile Asynchronous Parallelism）: 面向昇腾超节点的 MoE 计算通信优化，设计并实现基于局部同步的子 Tile 异步传输机制，减少全核同步与完整 Token 拼接等待，实现 GMM 计算与跨卡通信的流水重叠。相关论文在投。
- **Ascend-MoonEP**: 将 MoonEP 专家并行通信适配至昇腾，支撑 MoE dispatch/combine。

北大信息技术高等研究院 **编译器研发实习生** *2025-05~2028-01*
C/C++, MLIR, RISCV, Compiler Design

- **编程模型设计：**提出面向异构存算架构的任务式张量编程模型，以顺序语义描述任务组合，屏蔽显式通信与同步，支持“顺序编程、异步执行”
- **依赖驱动的异步编译：** 基于 MLIR 构建统一中间表示，自动推导任务间张量数据依赖，挖掘可并行任务并生成异步执行调度，保证执行结果与顺序语义一致
- **架构感知的后端优化：** 使用 C/C++ 实现面向多种 RISC-V SRAM 存算一体芯片的编译后端，结合应用特征分析，将可加速计算映射为芯片专用指令

Research & Publications

- **[Arxiv'26]** Jin Qin*, Tiancheng Hu*, Shiyan Wang, Junhao Hu, **Zexin Jian**, Yuzheng Wang, Haoyu Li, Chunwei Xia, Ying Liu, Pixian Zhan, Di Wang, Zhongzhe Hu, Huimin Cui, Tao Xie, Chenxi Wang. *CascadeEP: Asynchronous Expert Execution for MoE Prefill under Attention Imbalance*.
- **[ICS'26 workshop]** **Zexin Jian**, Shuhui Jia, Chunwei Xia, Di Wang, Chenxi Wang. *RV-IR: An MLIR-Based Architecture-Aware Intermediate Representation for Heterogeneous RISC-V AI Acceleration*.
- **[NeurIPS'24 CCF-A]** Zhihua Wen, Zhiliang Tian, **Zexin Jian**, Zhen Huang, Pei Ke, Yifu Gao, Minlie Huang, Dongsheng Li. *Perception of Knowledge Boundaries for LLMs via Semi-open-ended Question Answering*.
- **[ACL'23 CCF-A]** Zhihua Wen, Zhiliang Tian, Zhen Huang, Yuxin Yang, **Zexin Jian**, Changjian Wang, Dongsheng Li. *GRACE: Gradient-guided Controllable Retrieval for Augmenting Attribute-based Text Generation*.

</> 项目经历

LLM as Compiler **中科院计算技术研究所** *2024-09~2025-04*

LLM, Compiler Design, Machine Learning System

- 负责在大处理器芯片模型(LPCM)框架中设计并优化编译模块, 实现源代码到硬件适配机器代码的自动转换
- 通过引入大语言模型（LLM），成功实现了编译过程的自动化，支持硬件-软件协同设计。推动了编译器从人机协作到自动化的多级优化

mini RustOS **国防科技大学** *2024-09~2024-12*

Rust, X86, OS Design, Hybrid Kernel

- 使用 Rust 开发，从零实现了一个 X86 架构的实验性操作系统内核
- 本项目的出发点是探索不同的内核架构对内核安全性与性能的影响并尝试权衡二者。从宏内核出发，吸收借鉴微内核的设计模式来提高安全性的同时保证一定的性能

SysY Compiler **国防科技大学** *2024-02~2024-08*

C/C++, LLVM, RISCV, Compiler Design, Multi-Threads Parallel

- 使用 C/C++ 开发，为 SysY2022（C 语言子集）实现了一个功能齐全的编译器系统
- 主要工作包括前端的词法分析和语义分析，以及面向 RISC-V 架构的底层代码生成和优化

GROVE **国防科技大学** *2023-05~2023-10*

Python, LLM, Controllable Text Generation

- 主导研发 GROVE 检索增强故事生成框架，结合大语言模型、条件检索与迭代推理机制生成复杂情节故事
- 创新设计**追问式提示（Asking-Why）**构建证据链用于补全背景与逻辑，提升故事可读性与丰富度
- 在多个评测维度上取得领先效果，显著提升模型的复杂性、创造性与可控性

获奖情况

国家励志奖学金	**2023/2024**	*2023-09~2024-09*
国防科技大学计算机学院	**优秀学员·学习标兵**	*2021-09~2025-06*
全国大学生计算机系统能力大赛操作系统设计赛	三等奖	2025-08
第七届开源创新大赛“红山开源”操作系统-开源任务挑战赛	一等奖	2024-11
全国大学生计算机系统能力大赛编译系统设计赛	二等奖	2024-08
中国高校计算机大赛-团体程序设计天梯赛	三等奖	2024-04
第七届全军军事建模竞赛	二等奖	2023-12